

# Guia do Facilitador — A Arquitetura Oculta do ROI

SAB CIO 2026 (EBDI) · 7–9/out/2026 · Casa Grande Hotel, Guarujá · 30 minutos · Facilitador: Thiago Albieri (Sócio · Dados & IA)

Connect Session Sala 2 · Dia 2, 13h00 · título oficial: **"A Arquitetura Oculta do ROI: Otimizando Processos e Integrações para Escalar Agentes sem Inflar a Conta da TI"**.

Tese: **o ROI dos agentes é decidido em camadas que ninguém vê — processo, integração, custo por decisão e governo**. A sala vota, o resultado guia a conversa, o fechamento é DAMA-DMBOK.

**Contexto do dia (usar a favor):** até as 13h a sala terá ouvido governança de IA em três palestras (H Costa no Dia 1; Allos às 9h40; painel de shadow AI às 10h10). Não repetir — CONECTAR: "a governança que vocês ouviram às 9h40 é o freio; aqui vamos falar de quem paga a conta." Governança aparece nesta sessão como protetora do ROI, não como tese.

## 1 · Logística e controles (decorar)

| Item               | Como                                                                                                                                                                       |
|--------------------|----------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| Telão              | URL da página + <code>#telao</code> → PIN do facilitador. Manter notebook com carregador; a tela não dorme (wake lock).                                                    |
| Navegar            | Setas ← → do teclado (ou botões). <b>Enter</b> = abre a votação / revela o resultado no slide de provocação.                                                               |
| Participante       | Só a URL do QR (aparece sozinho nos passos de votação e na abertura). O celular deles mostra "aguarde" e acorda quando você abre a votação. Nunca vê parcial.              |
| Subir o stack      | <code>DB_SENHA=... docker compose up -d --build</code> na pasta do repositório → porta 8080 → expor com HTTPS (reverse proxy).                                             |
| Se a internet cair | Banner "MODO DEMO" aparece no telão. <b>Plano B: braço levantado por opção (A/B/C/D)</b> — a dinâmica continua idêntica. O slide da dinâmica já preparou a sala para isso. |
| Zerar votos        | Botão no telão — usar ANTES da sessão (limpa testes). Nunca durante.                                                                                                       |

## 2 · O arco em 21 passos (30 min)

| Min   | Passo                  | Condução                                                                                                                                                                                                                                                   |
|-------|------------------------|------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| 0–1,5 | 1 · Título + dinâmica  | "A Arquitetura Oculta do ROI" no telão, QR no ar: "escaneiem enquanto conversamos". Regra da casa: não existe resposta errada, existe fotografia honesta — voto anônimo.                                                                                   |
| 1,5–2 | 2 · Apresentação       | 30–45s. Engenharia USP + MBA Int. de Dados + sócio Apllos. Postura: executivo entre tecnologia e negócio.                                                                                                                                                  |
| 2–3,5 | 3 · Agentes (animação) | Deixar 1 loop rodar e fechar nas DUAS últimas linhas: o custo da decisão (9 chamadas, 4 sistemas, R\$ 3,10) e "rastreável de ponta a ponta". Frase: "cada decisão de agente tem uma conta — a pergunta é se alguém a enxerga". Rodapé diz que é simulação. |

|           |                                            |                                                                                                                                                                                                                                                                                                                                                                                     |
|-----------|--------------------------------------------|-------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| 3,5–5     | 4 · A provocação                           | "O ROI não mora no modelo — mora na arquitetura em volta dele." Conectar com as palestras da manhã (box acima). Ler POR COLUNA: fracasso já começou · a conta cresce escondida (o "1 mês" é RELATO — dizer isso em voz alta) · sem governo o ROI não se sustenta.                                                                                                                   |
| 5–6,5     | 5 · A arquitetura oculta (diagrama)        | Três frases: (1) "o modelo é UMA caixa — e raramente é onde a conta estoura"; (2) "integração, contexto e orquestração decidem quantas chamadas e quanto retrabalho cada decisão custa"; (3) "quem define essas camadas escala; quem não define paga cada caso como se fosse o primeiro". Clicar "Onde a Apllos atua" como revelação.                                               |
| 6,5–7     | 6 · Aquecimento                            | "De que setor você vem?" — destravar polegares.                                                                                                                                                                                                                                                                                                                                     |
| 7–25      | 7–15 · P1 a P9                             | ~45s de voto + ~90s de conversa cada. <b>Cortáveis se estourar: P6, P9 e P4</b> (nessa ordem). A P5 (reuso) e a P8 (trava) geram mais fala — reservar fôlego.                                                                                                                                                                                                                       |
| 25–26,5   | 16 · Fotografia (radar)                    | Deixar a sala LER o radar 5s. Dois eixos: Arquitetura (processo, integração, dados) × Economia (custo, modelo, reuso, medição). Apontar o vale do polígono.                                                                                                                                                                                                                         |
| 26,5–27,3 | 17 · DMBOK                                 | "A arquitetura oculta tem um nome antigo: gestão de dados." Quem já tem DMBOK tem parte da fundação que derruba o custo marginal.                                                                                                                                                                                                                                                   |
| 27,3–28,5 | 18 · Síntese: o que os 21% fazem diferente | Citar um resultado REAL votado e APONTAR (não ler) as trilhas: engenharia (integração reutilizável, harness, roteamento de modelos, skills, guardrails e evals) e organização (necessidades corporativas, processos redesenhados, ROI acordado antes, adoção, gates por evidência). "Quem toca só uma trilha paga duas vezes pela mesma fundação." Case: última linha, tom humilde. |
| 28,5–29   | 19 · Três perguntas de custo               | Pausar 2s entre cada pergunta. Fechar: "a IA não barateou o erro — nem a conta de uma arquitetura mal desenhada".                                                                                                                                                                                                                                                                   |
| 29–29,6   | 20 · Nove perguntas                        | "Valem para qualquer fornecedor — nós incluídos." O material cai no celular no próximo passo.                                                                                                                                                                                                                                                                                       |
| 29,6–30   | 21 · CTA                                   | Celulares recebem as nove perguntas + números com fonte. Encerrar NO tempo.                                                                                                                                                                                                                                                                                                         |

### 3 · As provocações — leitura por alternativa (cola de condução)

---

O telão mostra estas leituras ao revelar; a vencedora fica destacada. Use a linha da alternativa mais votada e UMA minoritária interessante.

#### P1 · Processo

Quando vocês colocam um agente num processo, o que acontece com o processo?

- A** Redesenhado → raro e caro, e é onde está o retorno. Quem conduziu: TI ou negócio? (*puxar ao microfone!*)
- B** Ajustado nos pontos de contato → meio-termo honesto; o risco é o agente herdar os gargalos.
- C** Encaixado como está → automatiza o desperdício — e a conta chega em tokens.
- D** Sem agente em processo → dá para desenhar processo e agente juntos desde o início.

Frase: agente colado no processo de ontem automatiza o desperdício de ontem.

#### P2 · Integração

Como os agentes de vocês se conectam aos sistemas corporativos (ERP, CRM, legados)?

- A** Camada reutilizável → já jogam o jogo do custo marginal. Quantos casos usam os mesmos conectores?
- B** Ponto a ponto → funciona no 1º caso; no 5º vira emaranhado que ninguém quer manter.
- C** RPA / tela / planilha → o agente fica refém da tela que muda sem aviso.
- D** Só leem documentos → o valor começa quando o agente age nos sistemas — com governo.

Frase: integração é a parte cara e invisível — o 2º caso só fica barato se o 1º deixou conectores.

#### P3 · Custo

Quem responde pela conta de inferência de IA na sua empresa?

- A** Ninguém → custo invisível está entre as causas dos 40% do Gartner (+ relato do budget anual em um mês).
- B** Agregado → não sobrevive ao CFO: qual caso de uso paga a conta?
- C** Por caso, com dono → o degrau que a maioria pula; falta o teto com corte.
- D** Teto + corte → o CFO já descobriu que virou aliado?

Contraste: Gartner 05/2026 — governança e custo entre as causas dos 40%.

#### P4 · Modelo por tarefa (*cortável*)

Quem decide qual modelo de IA roda em cada tarefa?

- A** Roteamento por tarefa → vocês medem a economia? Um dos maiores ganhos silenciosos.
- B** Um modelo para tudo → simples e caro: preço de especialista para tarefa de estagiário.
- C** Cada time o seu → sem padrão, sem poder de negociação nem reuso.
- D** O fornecedor decide → quando o preço mudar — e vai mudar —, vocês conseguem sair?

História de reserva: preço de token hoje é subsidiado; houve reajuste público de 10.000% num fornecedor (POD.IA #11).

## P5 · Reuso (a mais importante da sessão)

O segundo caso de uso de IA de vocês custou quanto, comparado ao primeiro?

- A** Bem menos → o sinal mais forte de maturidade da sessão. O que exatamente foi reaproveitado? (*puxar!*)
- B** Parecido → custo linear: 10 casos custam 10 vezes. É a curva que faz o CFO desligar no quarto.
- C** Mais caro → fundação refeita por área é o preço de não ter plataforma comum (a P9 volta a isso).
- D** Ainda no primeiro → então desenhem o primeiro como plataforma.

Este é o coração do título: "escalar sem inflar a conta" = custo marginal caindo.

## P6 · Dados (*cortável*)

Seus agentes de IA consomem dados de onde, na prática?

- A** Plataforma governada → fundação dos 21%; o catálogo cobre também modelos e agentes?
- B** APIs caso a caso → quem avisa o agente quando o contrato do dado mudar?
- C** Planilhas → lineage quebrado no primeiro elo.
- D** Não sabemos → resposta do agente vira opinião com boa aparência.

Frase: agente bom em cima de dado ruim só erra mais rápido — e cada erro repetido é custo.

## P7 · Medição

Como vocês medem o retorno de um agente em produção?

- A** Indicador + linha de base → é o que vira linha no P&L. Quem assina esse número?
- B** Horas economizadas → hora que não vira capacidade realocada não aparece no resultado.
- C** Adoção → condição, não retorno: muita gente usando algo caro pode ser só uma conta maior.
- D** Não medimos → o primeiro corte de orçamento leva o agente junto.

Conexão: a pocket "De piloto a P&L" do Dia 1 tratou de medir retorno — citar se alguém lembrar.

## P8 · A trava (6 opções)

O que mais trava seus agentes de chegar à produção?

- A** Segurança → quem desenha o freio libera o acelerador.
- B** Custo → teto por caso de uso resolve.
- C** Integração com legado → é onde o ROI se esconde; uma camada bem feita paga todos os casos seguintes.
- D** Qualidade → sem eval automatizado é opinião contra opinião.
- E** Processo e adoção → processo herdado derruba qualquer agente.
- F** Dados → a IA só expôs a dívida que já existia.

A trava campeã ganha 3–4 min de conversa.

## P9 · Modelo de governo (*cortável*)

Quem governa a IA na sua organização hoje?

- A** Central → escala? Quantos casos por semana antes de virar a fila que todos contornam?
- B** Cada área → é como nascem os 82% de shadow agents — e a fundação paga várias vezes.
- C** Híbrido → centralize o freio e a plataforma, descentralize a direção (data mesh).
- D** Ninguém → a governança acontece do mesmo jeito — pelo incidente.

Ponte com o ROI: plataforma central é o que faz o próximo caso custar menos.

## 4 · Leitura da sala (o telão calcula sozinho — sua fala por faixa)

**Índice < 2,0:** "A sala está onde o mercado está — ROI que não aparece é o terreno dos 40% do Gartner. A boa notícia: a arquitetura que muda isso é conhecida — próximos dois quadros."

**2,0–2,9:** "Meio do caminho: as fundações existem; o vão está em transformar casos isolados em plataforma reutilizável — é aí que o custo marginal cai e o ROI aparece."

**≥ 3,0 (o cenário que preocupa — vira teste, não lição):** "Autoavaliação acima do mercado — Deloitte mediu 21% maduras e 74% ACHAM que estarão prontas em 2 anos. Ou esta sala é a elite, ou fomos generosos. O teste honesto: o segundo caso de uso de vocês custou menos que o primeiro? Se sim, vocês são os 21% — e adoráramos conhecer o case de VOCÊS." O DMBOK vira elogio: "nota alta aqui quase sempre é fundação de dados bem-feita — falta projetá-la sobre os agentes; foi esse o salto do nosso case."

## 5 · Q&A antecipado (respostas de 15 segundos)

- **"Qual o ROI típico de um agente?"** — Não prometemos percentual: depende do processo e da linha de base. O que se garante é a mecânica — custo por decisão medido, custo marginal caindo a cada caso, indicador de negócio acordado antes do piloto.
- **"Onde a conta mais estoura?"** — Raramente no modelo. Estoura em integração refeita caso a caso, contexto inchado (tokens), retrabalho por dado ruim e modelo caro usado onde um menor bastava.
- **"Copilot/Bedrock/Vertex já não fazem isso?"** — Guardrail de modelo, sim; ciclo de decisão governado ponta a ponta (regra → gate humano → custo → prova), não. E nenhum nativo enxerga a nuvem do vizinho — por isso federação.
- **"Esse produto de vocês existe? Posso ver?"** — "É o acelerador que estamos construindo sobre o método que já operamos em cliente. O que está em produção é o trilho — o case. A sessão de desenho no seu contexto mostra como aterrissa aí."
- **"Isso não engessa o time?"** — O bloqueio acontece onde a empresa já dizia "não" em PDF. Agora o "não" é imediato, explicável e tem via de exceção com dono e prazo.
- **"E quando a regra está errada?"** — Regra que acumula exceções denuncia a si mesma. Governança de regras também é governada.
- **"Quanto tempo até valor?"** — Primeiro caso de uso governado em semanas; a régua completa sai de assessment curto.
- **"Como adotar com framework se a IA muda a cada 3 meses?"** — Governe INVARIANTES, não ferramentas: escopo de dado, gate humano, teto de custo e evidência valem para qualquer agente, de qualquer fornecedor, em qualquer versão. E política como código versionado torna a governança adaptativa: regra tem release e telemetria — a que acumula exceções denuncia a si mesma e evolui. A empresa troca de ferramenta; o governo fica. O DMBOK sobreviveu 20 anos de ondas tecnológicas exatamente por isso.
- **"Vocês confiam em IA decidindo?"** — Não confiamos: verificamos. Bloqueio, gate humano e prova no lugar de fé.

- **"Central ou descentralizado?"** — Nem um nem outro: federado. Centralize política, plataforma e observabilidade; descentralize a execução nos domínios — como o data mesh já ensinou.

**Diagrama da arquitetura oculta (passo 5, agora no fluxo):** três frases e seguir — (1) "o modelo é UMA caixa, e raramente é onde a conta estoura"; (2) "integração, contexto e orquestração decidem quantas chamadas e quanto retrabalho cada decisão custa"; (3) "quem define essas camadas escala; quem não define paga cada caso como se fosse o primeiro". Só então clicar **"Onde a Aplos atua"**: surgem em cascata sete setas (processo e método, instruções, skills, harness + roteamento, guardrails, memória enxuta, integrações reutilizáveis). Não explicar caixa por caixa.

## 5b · Histórias de campo para temperar a conversa (POD.IA #11 — João Carvalho, set/2026)

Relatos públicos de um praticante em grandes corporações brasileiras — contar como história ("ouvi num podcast do setor..."), nunca como estatística.

| Usar em                  | História / frase                                                                                                                                                                                                                                                                                                                                    |
|--------------------------|-----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| P1 · Inventário          | "Seus desenvolvedores estão usando IA que você NÃO disponibilizou. Quem cortou a verba de IA não cortou o uso — só mudou o destino: a informação da empresa está indo para fora." (Idem se a ferramenta oficial cair um mês: todos migram para a alternativa pessoal — vira problema de segurança, não de produtividade.)                           |
| P4 · Custo               | Relato de estouro de budget em 6 grandes empresas acompanhadas de perto: "o budget do ANO está indo em um mês". E o limite por equipe gera a cena: "mas o Robertinho usou tudo — eu estava de folga!". Fechar: hoje o preço de token é subsidiado (~2/3) para criar lock-in — houve reajuste público de 10.000% num fornecedor; a conta vai chegar. |
| P9 / adaptativo          | "O framework dado como determinístico três meses atrás MORRE." E a metáfora perfeita para CIO: "mudar o rumo de um caiaque é simples; mudar o rumo de um cruzeiro em cima da hora é complexo" — por isso governe invariantes, não ferramentas.                                                                                                      |
| Síntese · Soberania      | "Crie o seu harness próprio onde o MODELO é só um plugin, desacoplável a qualquer momento. Não fique refém." (Uma empresa citada ficou ~1 mês sem IA quando o fornecedor mudou a monetização.)                                                                                                                                                      |
| Slide 18 · Custo do erro | A origem da nossa escalada: "Qualquer pessoa pode desenvolver? Pode. Numa POC, o custo do erro é baixo — vai lá e faz. Qual é o custo do erro numa corporação de bilhões?"                                                                                                                                                                          |
| DMBOK / documentação     | "O que não está escrito NÃO EXISTE. A memória coletiva virou a parte mais importante do software" — e a morte do dev-herói: "cuspir código virou commodity; o agente não vai telefonar para o salvador da salinha".                                                                                                                                 |
| Adoção (se perguntarem)  | Três estágios: adoção → medição de impacto → sustentabilidade ("a conta fecha?"). E adoção não é só engenharia: disponibilizar + treinar + MUDAR O PROCESSO — se só os devs adotam, a produtividade não aparece no faturamento.                                                                                                                     |

## 6 · Os números da sessão (falar SEMPRE com fonte e data)

| Número | O que é | Fonte |
|--------|---------|-------|
|--------|---------|-------|

|                |                                                                                                                                 |                                                             |
|----------------|---------------------------------------------------------------------------------------------------------------------------------|-------------------------------------------------------------|
| 40%            | empresas que vão desligar/rebaixar agentes até 2027 (governança + custo)                                                        | Gartner, 05/2026                                            |
| 82%            | têm agentes que a própria TI desconhece (shadow agents)                                                                         | Cloud Security Alliance, 04/2026                            |
| 21% / 74%      | governança madura hoje / acham que terão em 2 anos                                                                              | Deloitte, 08/2026                                           |
| 3              | fabricantes de guardrails comprados em 12 meses (Portkey→PANW, Lakera→Check Point, Protect AI→PANW) — guardrail virou commodity | anúncios públicos                                           |
| 0              | ferramentas nativas que executam a política da SUA empresa entre nuvens                                                         | análise Aplos (Cedar × Entra × Model Armor × Unity Catalog) |
| 2% / R\$ 50 mi | sanção LGPD por infração — agente também é tratamento de dados                                                                  | LGPD / ANPD                                                 |
| 12/2027        | obrigações de alto risco do EU AI Act (rastreadabilidade incluída)                                                              | EU AI Act                                                   |
| —              | ISO/IEC 42001: sistema de gestão de IA, já certificável                                                                         | ISO                                                         |

## 7 · Regras de conduta (inegociáveis)

- Nomes de clientes SÓ em conversa privada — no palco: setores ("indústria siderúrgica", como o site publica).
- Métricas próprias faladas = somente as publicadas em [aplos.com/cases](https://aplos.com/cases).
- Nunca prometer percentual de ganho; nunca "somos os únicos"; simulações sempre anunciadas como simulações.
- Nunca corrigir um voto — "fotografia honesta". Contrastar com dado de mercado, não julgar.
- DAMA-DMBOK® é marca da DAMA International — referência de mercado, sem endosso.

## 8 · Checklist pré-evento

- ☐ Stack no ar com HTTPS num subdomínio próprio; testado em 3+ celulares (4G e Wi-Fi).
- ☐ Trocar o PIN do telão; ZERAR os votos de teste antes de entrar no palco.
- ☐ Ensaiar 1× com cronômetro simulando conversas de 90s (alvo: P9 termina no min 25).
- ☐ Notebook: carregador, brilho máximo, notificações off, aba #telao logada com PIN.
- ☐ 4G/5G próprio como rede de contingência do notebook.
- ☐ Decidir na véspera: cortar P3/P6/P8 conforme o tamanho da sala e o apetite de conversa.
- ☐ Foto do palestrante no slide 2 (opcional): foto-palestrante.png na pasta + rebuild.

Gerado em 28/09/2026 a partir do repositório da sessão (votacao/). Recriar o PDF: [editar guia-facilitador.html](#) e rodar o comando do README.